

Backtest-Bericht: Regel-System vs. KI-Filter

Auswertung des LLM-Entscheidungs-Layers auf echten Marktdaten · Stand: 20.06.2026 ·
vertraulich, intern

Kurzfassung

Wir haben erstmals den **KI-Layer** (ein Large-Language-Model, das jeden vom Regelwerk als handelswürdig markierten Setup gegenprüft) in einem Backtest auf **echten XAUUSD-M1-Daten** laufen lassen und gegen das reine Regel-System verglichen. Zwei Kernergebnisse:

- 1. Ein technisches Problem wurde gefunden und behoben.** Der KI-Layer lief bisher live praktisch nie durch – jeder Aufruf lief in einen 30-Sekunden-Timeout und fiel still auf das Regelwerk zurück. Ursache: das Modell denkt zu lange. Nach dem Fix laufen jetzt **100 % der Aufrufe** sauber durch.
- 2. Der KI-Filter ist extrem konservativ.** Von 749 Setups, die das Regelwerk handeln würde, hat die KI **99 % abgelehnt** und über 10 Handelstage nur **1 Trade** zugelassen (gewonnen). Das vermeidet die Verluste des Regel-Systems – ist aber bei n = 1 noch **kein Beweis** für einen echten Edge.

Ergebnis im Direktvergleich

Identischer Code, identisches Datenfenster (~10 Handelstage, 10.6.–19.6.2026, echte M1-Bars). Einziger Unterschied: ob der KI-Filter aktiv ist.

Kennzahl	Regel-System	Mit KI-Filter
Anzahl Trades	35	1
Trefferquote (Winrate)	45,7 %	100 % (1/1)
Ø Ergebnis pro Trade	-0,27 R	+0,94 R
Profit-Faktor	0,49	n. a. (kein Verlust)
Netto-Ergebnis	-476 \$	+47 \$
Max. Drawdown	774 \$	0 \$

Lesehilfe: 1 R = das pro Trade riskierte Geld. „-0,27 R im Schnitt“ heißt, das Regel-System verliert im Mittel ein gutes Viertel des Risikos je Trade – über 35 Trades summiert sich das.

Wie der KI-Filter entscheidet

Das Modell wird auf jedem Bar mit Score ≥ 65 (der Schwelle, ab der das Regelwerk handelsbereit ist) befragt. Über 749 solcher Bars im Testfenster:

KI-Entscheidung	Anzahl	Anteil
Kein Trade (hartes Veto)	550	73 %
Beobachten / noch nicht	160	21 %
Einstieg (Entry)	6	0,8 %

Das Regelwerk hätte auf **686** dieser 749 Bars einen Einstieg genommen – die KI hat davon **680 abgelehnt (99,1 %)**. Von den 6 Einstiegs-Signalen wurde nur eines ein echter Trade (die übrigen

scheiterten an Qualifikation / Risiko / bereits offener Position). Dieser eine Trade gewann.

Ehrliche Einordnung

Was gesichert ist: Der KI-Layer funktioniert jetzt technisch zuverlässig (749 von 749 Aufrufen erfolgreich, im Schnitt ~10 s je Aufruf). Das war zuvor nicht der Fall.

Was NICHT gesichert ist: Die Schlagzeile „-476 \$ → +47 \$“ beruht auf **einem einzigen Trade**. Das ist statistisch nicht aussagekräftig. Real ist Folgendes passiert: Der KI-Filter hat ein netto-verlustreiches Regel-System in eines verwandelt, das **praktisch nicht handelt** (1 Trade in 10 Tagen). Das umgeht die Verluste – ob es ein echter Vorteil ist oder schlicht „sagt zu fast allem nein und hatte einmal Glück“, lässt sich bei $n = 1$ nicht unterscheiden.

Wichtiger Vorbehalt: Dieser Lauf lief mit **abgeschaltetem „Reasoning“** (dem tiefen Nachdenk-Modus des Modells), weil dieses sonst ~55 s je Aufruf braucht. Das ist also das „schnelle“ Modell – das tiefere könnte mehr oder weniger zaghaft entscheiden.

Fragen an dich, Joshua

Wir wollen wissen, in welche Richtung wir das System steuern sollen. Konkret:

Ist 99 % Veto sinnvoll? Das Regelwerk liefert bei Score 65–74 (Vorbereitungs-Band) viele Setups, die die KI fast alle ablehnt. Ist das „richtig streng“ im Sinne deiner Strategie, oder filtert die KI zu viel weg?

Wo liegt dein Mindest-Setup? Welche Bedingungen müssen erfüllt sein, damit ein Trade für dich klar handelbar ist (Struktur, Liquidität, Session)? Daran können wir die KI bzw. das Regelwerk eichen.

Lieber selteneres, präziseres Handeln – oder mehr Aktivität? Der KI-Filter tendiert klar zu „selten, aber sicher“. Passt das zu deiner Vorstellung von der Strategie?

Empfohlene nächste Schritte

Längeres Datenfenster (Priorität 1). Mehrere Wochen/Monate echte M1-Daten, damit die KI auf eine zweistellige Trade-Zahl kommt – nur so wird die Trefferquote belastbar und die $n = 1$ -Frage geklärt.

Reasoning-Stichprobe. 30–50 Setups mit dem tiefen Nachdenk-Modus (jetzt technisch möglich), um zu sehen, ob das tiefere Modell mehr valide Einstiege findet.

Live im Beobachtungs-Modus. Da der KI-Layer jetzt funktioniert, mitlaufen lassen (ohne echte Orders) und über Tage echte Entscheidungen sammeln – als Realitäts-Check zum Backtest.

Vergleichsfälle & Trade-Bewertung

Die echten Trades aus dem Backtest – und was Regelwerk und KI an konkreten Setups gemacht haben.

1. Bewertung der 35 Regel-Trades

Alle 35 Trades enden auf eine von zwei Arten: erster Take-Profit erreicht (Gewinn) oder Stop-Loss (Verlust). Daraus wird das Kernproblem sichtbar:

	Gewinner	Verlierer
Anzahl	16	19
Ø Ergebnis	+0,57 R	-0,99 R
Ausgang	Take-Profit 1	Stop-Loss

Das Problem in einem Satz: Die Gewinner werden am ersten Take-Profit gedeckelt (im Schnitt nur +0,57 R), während die Verlierer fast den vollen Stop laufen (-0,99 R). Bei 46 % Trefferquote ergibt das ein Minus. Bester Trade: **+2,37 R** (Short, 18.6.); schlechteste: drei Stops in Folge zu je **-1,20 R**.

2. Hauptverlustquelle: das Stapeln von Trades in der Chop-Zone

Das Regelwerk feuert oft **mehrere fast identische Einstiege im Minutentakt**. Bricht die Zone, kassiert es gleich mehrere Stops hintereinander. Drei reale Beispiele:

Zeitpunkt	Richtung	Einstiege	Ergebnis
19.6. 08:25–08:27	Short	3 in 3 Minuten	alle Stop-Loss (-0,80 / -0,71 / -0,74 R)
16.6. 01:43–01:59	Short	3 in 16 Minuten	alle Stop-Loss (-1,20 R)
12.6. 02:13–02:24	Long	3 in 11 Minuten	alle Stop-Loss (-0,77 / -1,02 / -0,99 R)

Ein diskretionärer Trader nimmt **eine** Position an der Zone – der Bot stapelt drei. Bemerkenswert: Der KI-Filter hat **jeden einzelnen** dieser Cluster-Trades abgelehnt.

3. Dein Vergleichsfall: der Short bei ~4168

Was du markiert hast: Short aus der Supply/FVG-Zone bei ~4168, Ziel an der tieferen Liquidität (~4144).

Was der Bot „gesehen“ hat: In der Zone 4158–4178 erzeugte das Regelwerk am 10.6. **37 Short-Signale** (Score 65–67) – es hat denselben Short also klar erkannt.

Was tatsächlich passierte: Kein einziger dieser 37 wurde dort ausgeführt – die Ausführungs-Gates (Qualifikation + Tageslimit) hielten den Bot raus. Ausgeführt wurde erst **~28 USD tiefer bei 4140**. Der Bot steigt also nicht an der Supply-Zone ein wie du, sondern **läuft dem Move hinterher**.

Und die KI? Sie hätte **alle 37** abgelehnt (NO_TRADE).

Heißt für deine Strategie: An genau deiner Zone war der Bot **dreifach** zurückhaltend – erst das Regel-Gate, dann die verspätete Ausführung, dann das KI-Veto. Hier müssen wir wissen: Ist der Einstieg **direkt an der Supply-Zone** (wie bei dir) das Ziel – dann müssen wir die Ausführung dort schärfen, nicht erst 28 USD später.

4. Regelwerk und KI sind sich praktisch nie einig

Der vielleicht wichtigste Befund: Von den **35 Trades, die das Regelwerk ausgeführt hat, hätte die KI alle 35 abgelehnt**. Die 6 Einstiege, die die KI ihrerseits zuließ, lagen an völlig anderen Stellen (einer davon wurde der eine Gewinn-Trade, +0,94 R). Die KI ist also nicht „Regelwerk plus Filter“, sondern ein fast vollständig **eigenes, viel passiveres System**.

Das ist Chance und Risiko zugleich: Die KI unterbindet das schädliche Stapeln zuverlässig – aber so radikal, dass am Ende fast nicht mehr gehandelt wird.

Die Grundsatzfrage an dich

Die Verluste kommen aus zwei Quellen: (a) gedeckelte Gewinner / volle Verlierer (Exit-Logik) und (b) Über-Handeln in Seitwärtsphasen. Wir sehen zwei Wege – welcher passt zu deiner Strategie?

Weg A – KI führt	Weg B – Regelwerk schärfen
Selten, aber gezielt. Die KI filtert 99 % weg und handelt nur Top-Setups. Risiko: handelt evtl. zu wenig (n = 1).	Cluster-Sperre (nur 1 Einstieg je Zone), höhere Schwelle, besseres Exit (Gewinner laufen lassen). KI nur als sanfter Zusatzfilter.

Methodik & Setup (für Technik-Interessierte)

Daten: 10.785 echte XAUUSD-M1-Bars (Broker-Feed), 10.6.–19.6.2026. | Modell: minimax-m3 via OpenRouter. | KI-Gate: Score ≥ 65 . | Slippage 0,50 / Spread 0,30 (fix). | Risiko-/Positionslogik identisch in beiden Läufen. | Der KI-Lauf nutzte exakt denselben Code-Stand wie das Regel-System (nur der KI-Filter zugeschaltet); das Live-System wurde dabei nicht verändert (Beobachtungs-Modus). | Behobenes Problem: Aufruf-Timeout 30 s $\rightarrow$ 60 s; Reasoning standardmäßig aus. | Laufzeit des KI-Backtests: 2,7 h, 749 Aufrufe, 0 Fehler.

Hinweis: Dieser Bericht ist eine interne technische Auswertung, keine Anlageberatung oder Performance-Zusage. Backtest-Ergebnisse sind keine Garantie für künftige Resultate; die KI-Stichprobe umfasst n = 1 Trade.